实验反馈之后， 如何让 Codex 排序更稳

科研程序集成 · RNA 与蛋白质变体的实测对照

gpt-6.1-sol / high；Fast 关闭；工具禁网。程序与隐藏测量结果由操作系统隔离。

要解决的问题

分子工程团队测完一批变体后，需要用有限反馈更新剩余候选的排序。Codex 能自行构造特征、拟合模型，但不同会话对读数变换、组合效应和模型族的选择会波动。本项目改进这一环节：独立生成三份科研程序，固定等权平均它们的排名。

同一批反馈，三种对照

每个程序看到相同的 32 条初始测量和 64 条随机反馈；其余 186 条结果仅由评估器持有。单次 Codex 固定取第 00 份程序；同预算对照先生成相同三份程序，再用反馈五折交叉验证选一份；集成保留全部三份。指标为有符号 Spearman，越大越好。

RNA：10 个 assay 的描述性宏平均，相对单次 Codex +0.0157（8/10 提升）；相对同预算 CV 单程序 +0.0177（8/10 提升）。旧 6 个 assay 经交付恢复才完整，另 4 个验证的主要标准未通过；旧队列更强的重复 CV 对照区间也包含 0。

蛋白质：10 个 assay

Assay	单次 Codex	CV 选一个	集成	增量 vs CV
GFP	0.530	0.543	0.582	+0.0386
PABP	0.499	0.554	0.534	-0.0193
GCN4	0.420	0.382	0.413	+0.0312
AMFR	0.810	0.828	0.828	+0.0004
HIS7	0.420	0.412	0.420	+0.0074
GRB2	0.658	0.602	0.666	+0.0646
YAP1	0.383	0.383	0.463	+0.0803
PHOT	0.880	0.880	0.861	-0.0184
KRAS 丰度	0.472	0.465	0.493	+0.0284
YNZC	0.801	0.795	0.832	+0.0367

10 assay 等权描述性汇总：相对 CV 单程序 8/10 提升，平均 +0.0250，95% 区间 [+0.0058, +0.0445]；相对单次 Codex 8/10 提升，平均 +0.0221。新增 6 个冻结验证（交付恢复后）：平均 +0.0332，5/6 提升，冻结质量条件满足。原 18 个会话有 1 次容量失败，冻结代码经 1 次额外交付调用恢复；原运行验收仍未通过。

实现与适用边界

任务示例

Query：“给你参考序列、测量端点、32 条初始测量与 64 条新增反馈，请对剩余 186 条已有变体排序，交付可复用的预测程序。”

Input：case.json 包含 reference_sequence、context、support(id, mutation, sequence, fitness) 与 query(id, mutation, sequence)。query 不含测量结果。

工作流

① 独立建模：三个独立工作区使用完全相同的输入，原生 Codex 自由建模和验证。 ② 可执行：提交 propose(case, assignment)，每次从传入反馈重新拟合；宿主重复执行，检查 ID、有限分数与确定性。 ③ 固定集成：三份分数各自转为百分位排名，再等权平均。测试结果不参与程序、权重或符号选择。 ④ 盲评：全部计划生成与反馈 CV 结束后，评估器才读取隐藏结果。

为何这样改

原生会话通常经历数据检查、特征与假设构造、反馈验证选模、程序交付四个环节。改进集中在“方案生成后的聚合”和“交付验收”。它保留 Codex 的自由建模能力，通过不同科学程序的互补减小波动；收到规范 ready 后独立验收，避免 CLI 退出延迟把已经交付的程序判成超时。三个会话获得的是同一批 96 条测量，额外实验信息为零；科学生成会话数为单次对照的三倍，token 与耗时按实际记录。

仍会失败在哪里

模型选择：少量反馈上的验证优胜者可能在未测变体上退化。CV 架构也已由全部反馈生成，因此不是完全嵌套验证。 科学假设：序列特征和组合效应可能忽略真实结构、伙伴及读数噪声；稳定性、荧光与生长端点不能互换解释。 集成：PABP 比 CV 选出的单程序低 0.0193；平均排名会稀释优胜者，也可能保留共享偏差。 交付：原 36 次 RNA 会话有 21 次未按旧等待规则完成；20 次额外调用仅恢复冻结程序的交付。新增 protein 又有 1 次模型容量失败，经额外交付调用恢复，代码未变。

阶数诊断：GRB2、YAP1 的双突变子集相对同预算单程序增量分别为 +0.0651、+0.0836；PHOT 多个同阶数子集仍退化。完整分层表见附件。

可以支持的结论

这是一套可运行、可盲评的反馈后排序工作流。RNA 有正向改善信号；是否优于强单程序仍受对照和小样本影响。蛋白质结果单独报告；10 个 assay 的合并分析是描述性汇总，不替代新增 6 个 assay 的冻结验证。AMFR 与 YNZC 同属 Tsuboyama 研究，另保留按研究分组的敏感性分析。实测是历史测量的离线回放，64 条反馈为随机抽取，没有主动选样或新增湿实验；公开数据的预训练暴露无法排除。

复现：demo.py 冷启动重拟合冻结程序；run.py 可启动新原生会话。完整输入、程序、调用记录、统计与原失败状态见 ZIP 附件。

行业岗位与日常任务

场景：分子工程团队。计算、平台与实验岗位协作完成“已有测量 → 建模 → 候选排序 → 实验反馈”。下列比例是典型工作周的规划估计，每个岗位合计 100%；并非调研统计或个人工时记录。

计算生物学研究员

任务 / 时间	代表性 query	input
文献机制 20%	说明读数能代表哪些功能。	方法段、WT、assay 说明
数据质检 25%	检查重复、编号与分数方向。	变体 CSV、端点 JSON
模型评估 30%	比较模型并定位高阶突变误差。	固定划分、预测、隔离标签
候选决策 15%	用新增反馈更新下一批排序。	参考序列、已测反馈、候选池
结果报告 10%	总结收益、失败与统计边界。	逐任务指标、调用账本

科研 Agent / 平台工程师

任务 / 时间	代表性 query	input
协议设计 15%	将排序需求写成验收合同。	预算、候选 ID、评价指标
证据接口 20%	将证据映射到突变位点。	序列、比对、结构位点表
工具开发 40%	实现幂等测量提交和反馈更新。	submit 接口、请求 ID、预算
对照实验 15%	在同输入下比较原生与改进流程。	模型配置、任务包、盲评器
运行追踪 10%	定位失败阶段和重复请求。	事件日志、退出码、用量

实验研发工程师

任务 / 时间	代表性 query	input
实验设计 20%	整理目标、可测数量与约束。	端点、候选清单、测量预算
执行排程 40%	核对样本批次与仪器排程。	样本表、时段、记录模板
读数质检 20%	识别批次异常并导出反馈。	重复读数、批次、对照样本
后续决策 10%	审阅下一批推荐及证据不足项。	候选、已测结果、不确定性
团队沟通 10%	解释测量与原假设的差异。	反馈汇总、旧预测、研究假设

数据来源：RNAGym、ProteinGym 的公开历史实验。GCN4 原研究测转录激活活性，但导出 context 标为 Binding；此轮保留冻结输入，作为元数据限制，不解释为结合亲和力。原研究：Staller et al., Cell Systems (2018), doi:10.1016/j.cels.2018.01.015。